Análisis multivariante y validación de modelos

Juan Miguel Cano Mazón
Unidad de Metabolómica HUMV-IDIVAL
10 de noviembre de 2026



Picos de Europa

Fuente: https://viajes.nationalgeographic.com.es/a/guia-para-conocer-y-disfrutar-picos-europa_17354

El otro día

- La preparación del análisis
  muestras, blancos, QC, orden de inyección
- El análisis univariante
  volcano plot y FDR

Hoy

aunque ya asomó algo, como el PCA

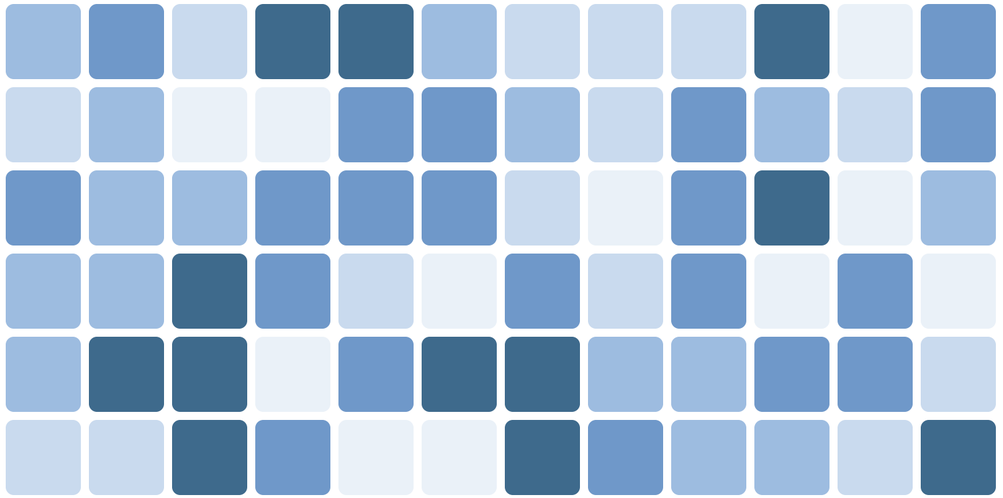
El análisis multivariante, a fondo

- PCA, clustering, PLS-DA y Random Forest
- validación de los modelos

El punto de partida: la matriz de características

inyecciones →

compuestos
↓

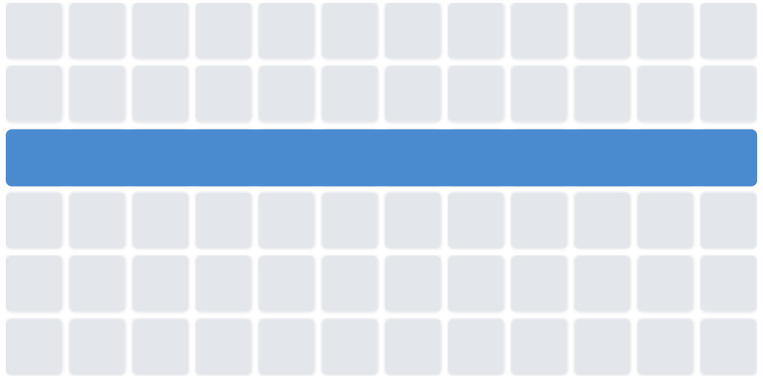


Cada fila, un **compuesto**

Cada columna, una **inyección**

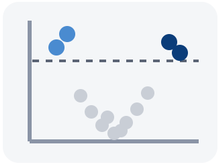
Cada casilla, **cuánto** hay de ese compuesto en esa inyección

Univariante y multivariante

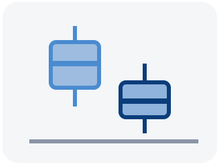


Univariante

Un compuesto cada vez



Volcano

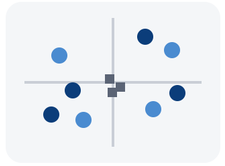


Cajas por grupo

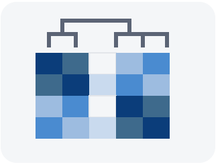


Multivariante

Todos los compuestos a la vez



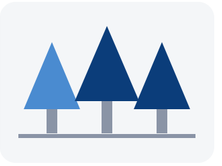
PCA



Heatmap



PLS-DA



Random Forest

Métodos multivariantes

No supervisado

sin decirle los grupos

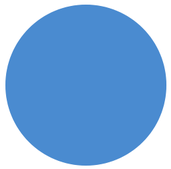
PCA
Clustering

Supervisado

diciéndole los grupos

PLS-DA
Random Forest

Ejemplo simplificado



Ana

sana



Blas

sano



Carmen

sana



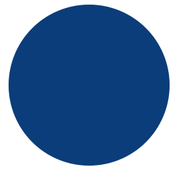
Dani

enfermo



Elena

enferma



Fede

enfermo

A cada uno le medimos 5 compuestos

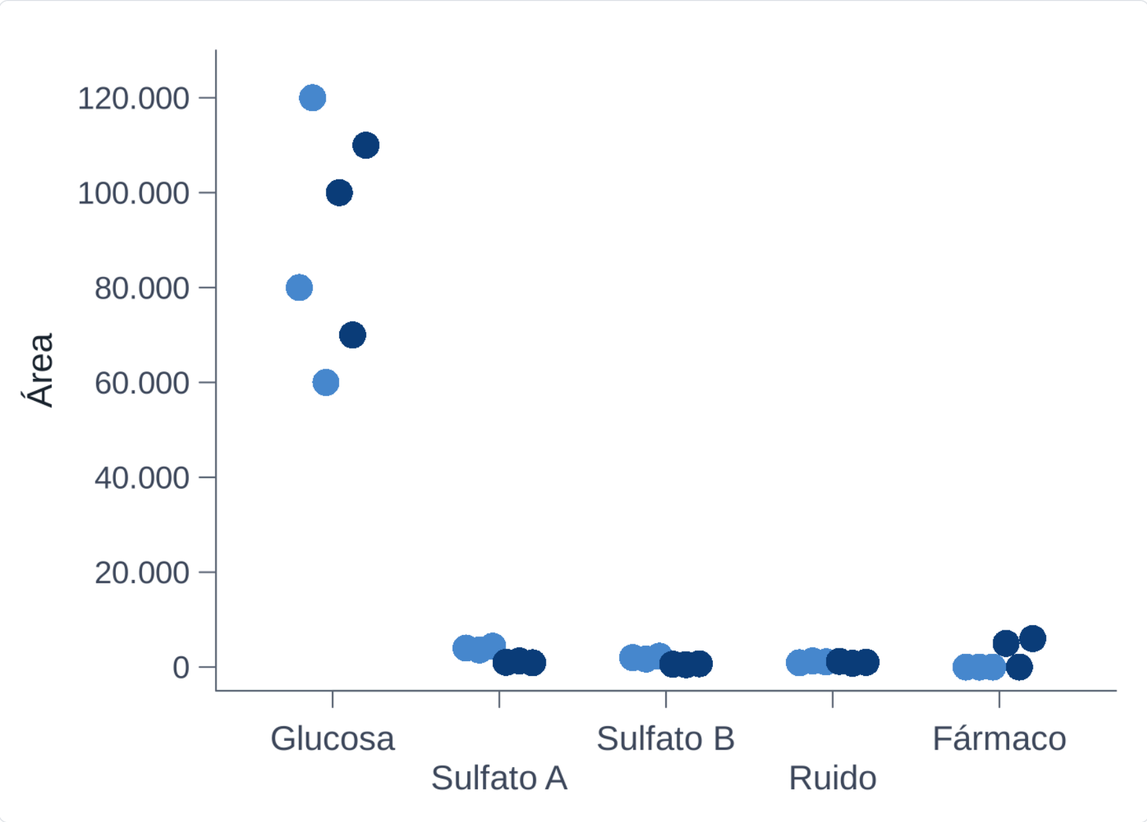
Glucosa **Sulfato A** **Sulfato B** **Ruido** **Fármaco**

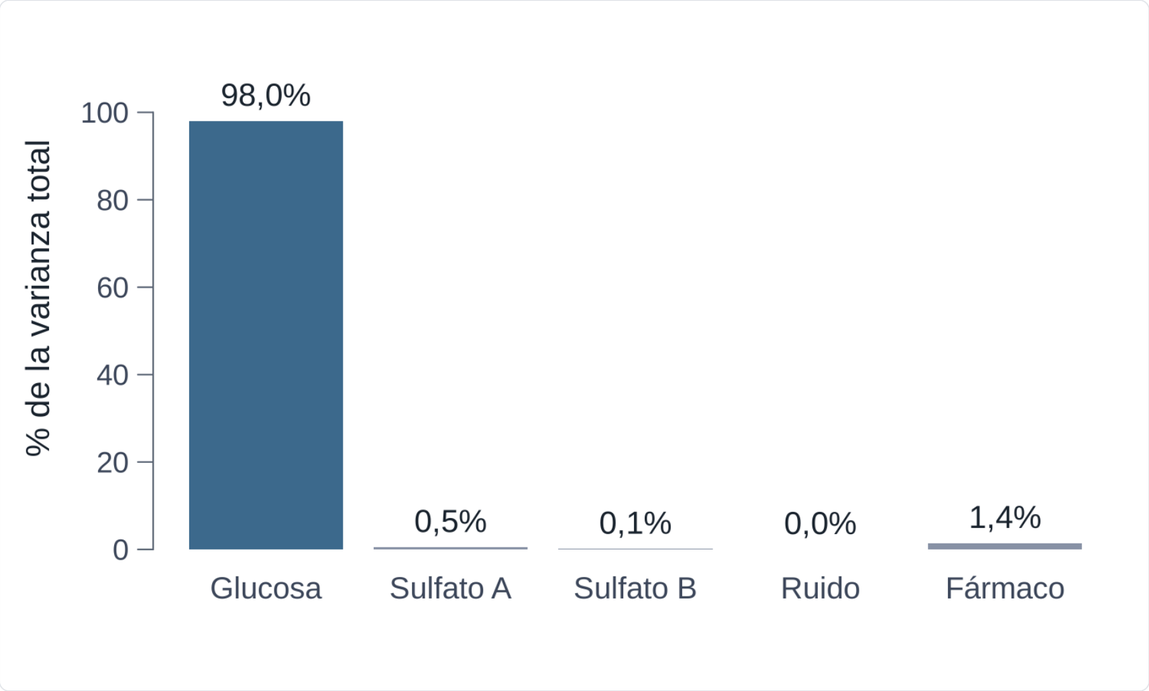
Áreas de pico

Persona	Glucosa	Sulfato A	Sulfato B	Ruido	Fármaco
Ana	80.000	4.000	2.000	900	10
Blas	120.000	3.600	1.700	1.300	10
Carmen	60.000	4.400	2.300	1.100	10
Dani	100.000	1.000	600	1.200	5.000
Elena	70.000	1.300	500	800	10
Fede	110.000	900	700	1.000	6.000

¿Qué distingue a los enfermos de los sanos?

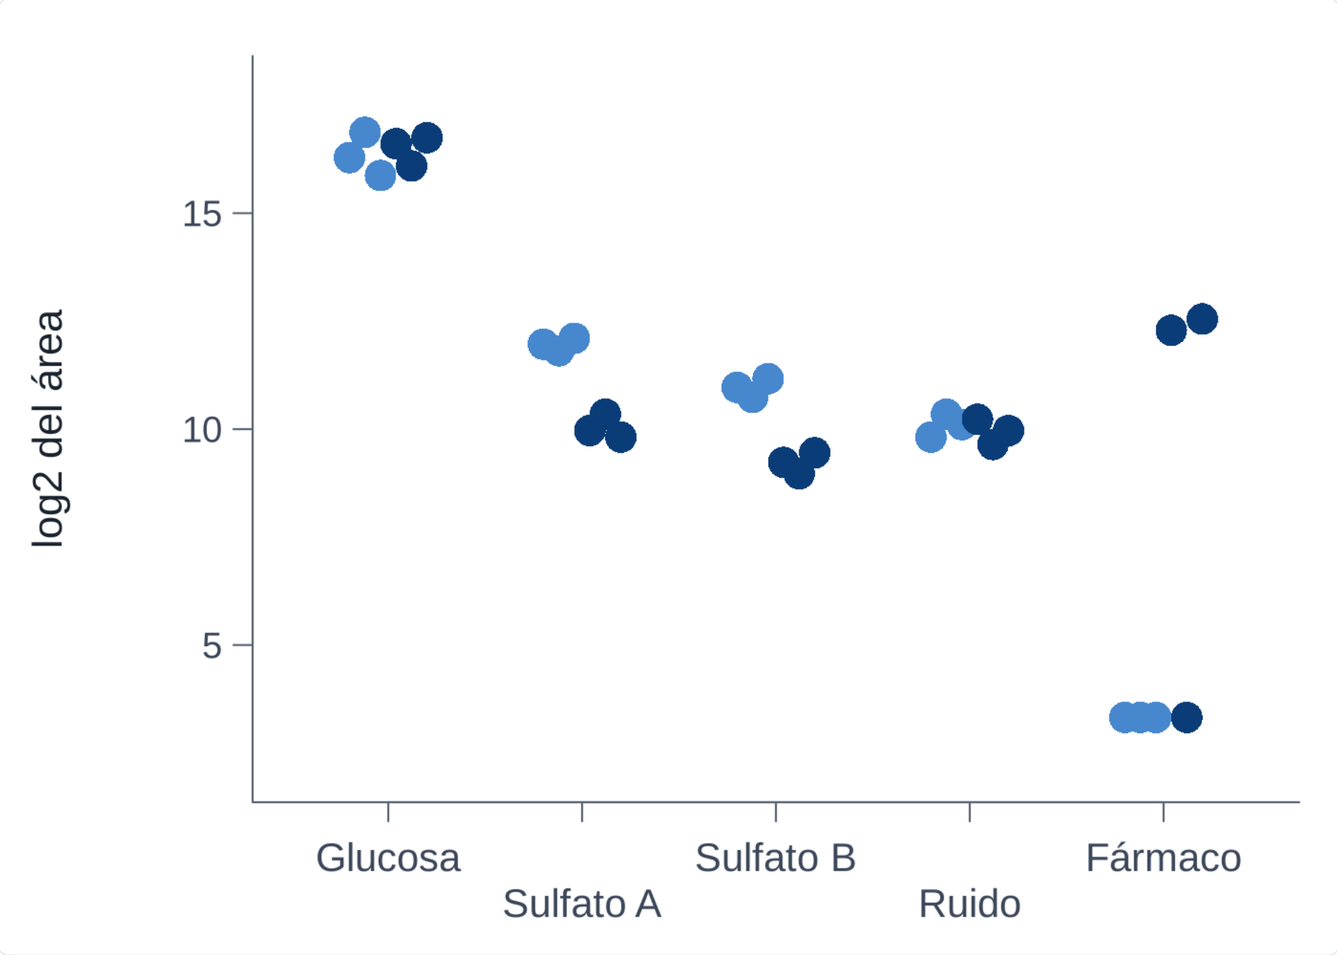
Datos sin transformar





La glucosa acumula el **98%** de la varianza por su escala

Transformación logarítmica



En log2, **el doble es siempre +1**

1.000 → 2.000
50.000 → 100.000
las dos, +1

Ya se ven los **sulfatos bajos** y el **fármaco** en dos enfermos

Centrado y escalado de Pareto

1. Centrar

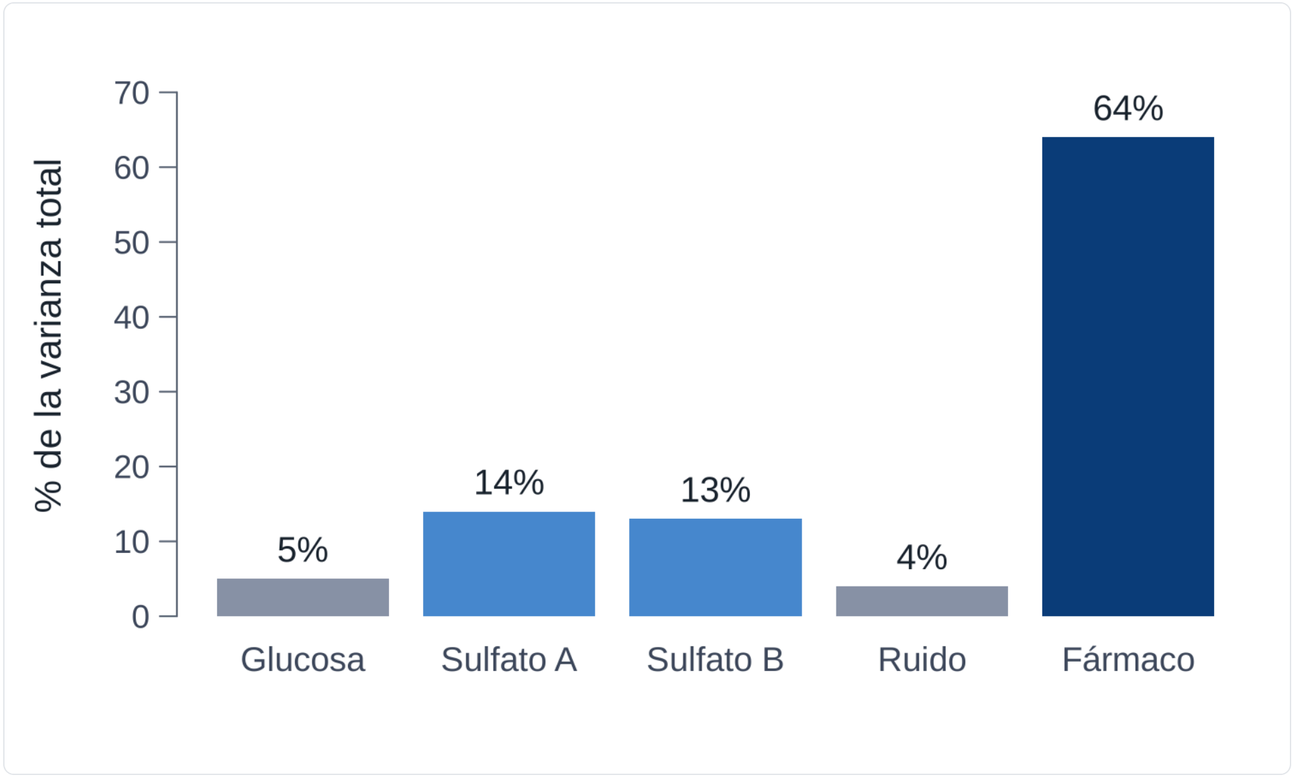
Restar la media de cada compuesto

2. Escalar

Dividir por la raíz de su desviación típica

Sulfato A de Ana

(11,97 − 11,00) / √1,07 = **0,93**



La glucosa ya no manda. Ahora el que más grita es **el fármaco**

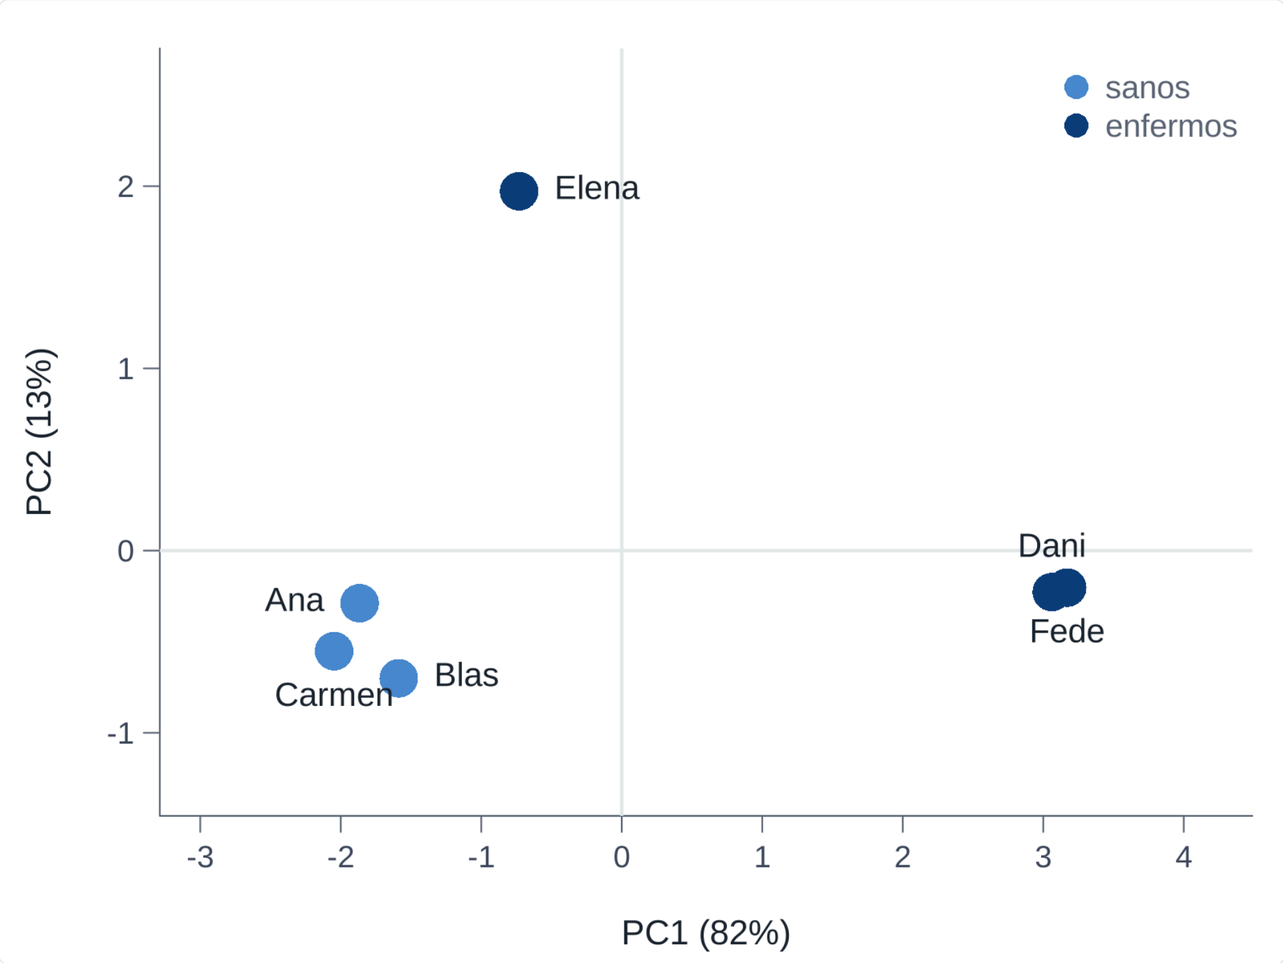
1. No supervisado

Sin información de los grupos

PCA
resumir en pocas componentes

Clustering
agrupar por parecido

PCA, gráfico de scores



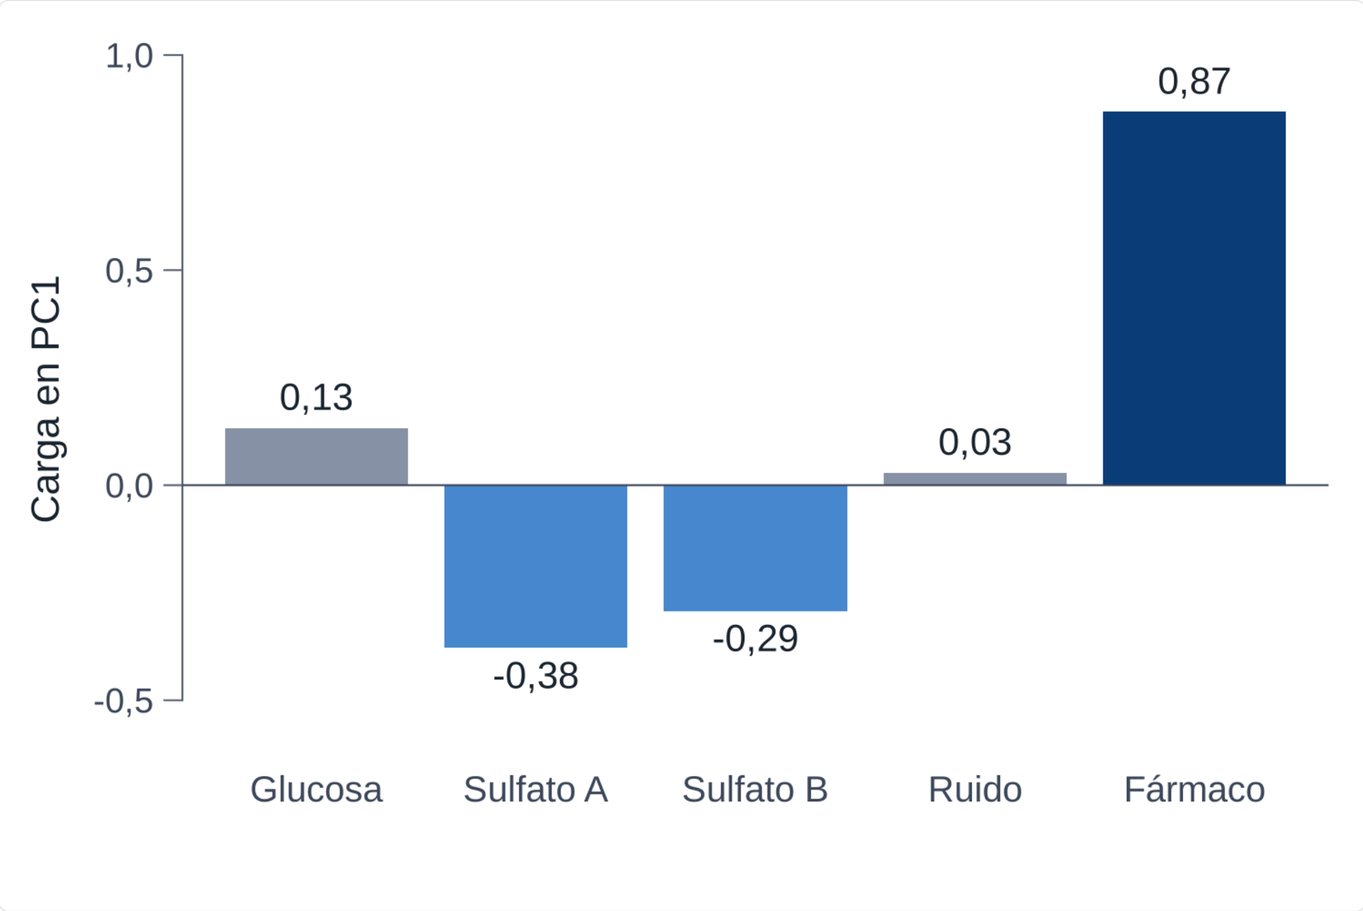
PC1 explica el 82% de la varianza

A la derecha, **Dani y Fede**

Elena, enferma, cerca de los sanos en PC1

¿Qué es PC1?

PCA, cargas de la PC1

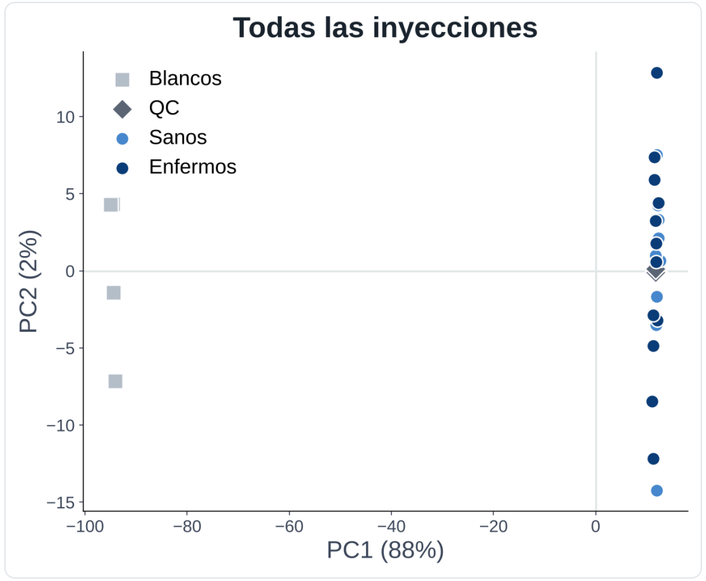


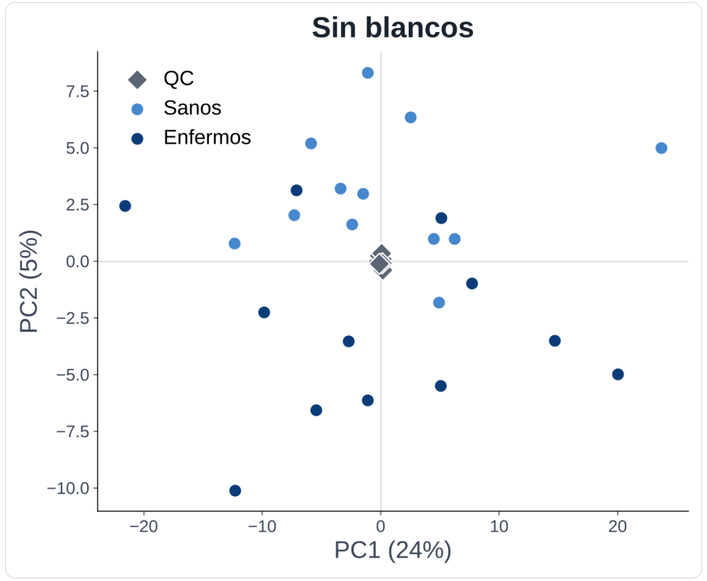
Carga: peso de cada compuesto en la componente

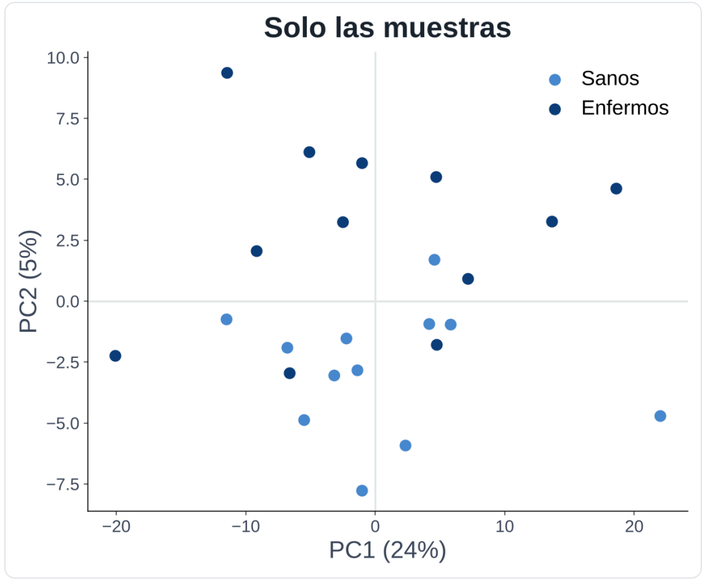
0,87
el fármaco

PC1 ≈ fármaco

PCA como control de calidad







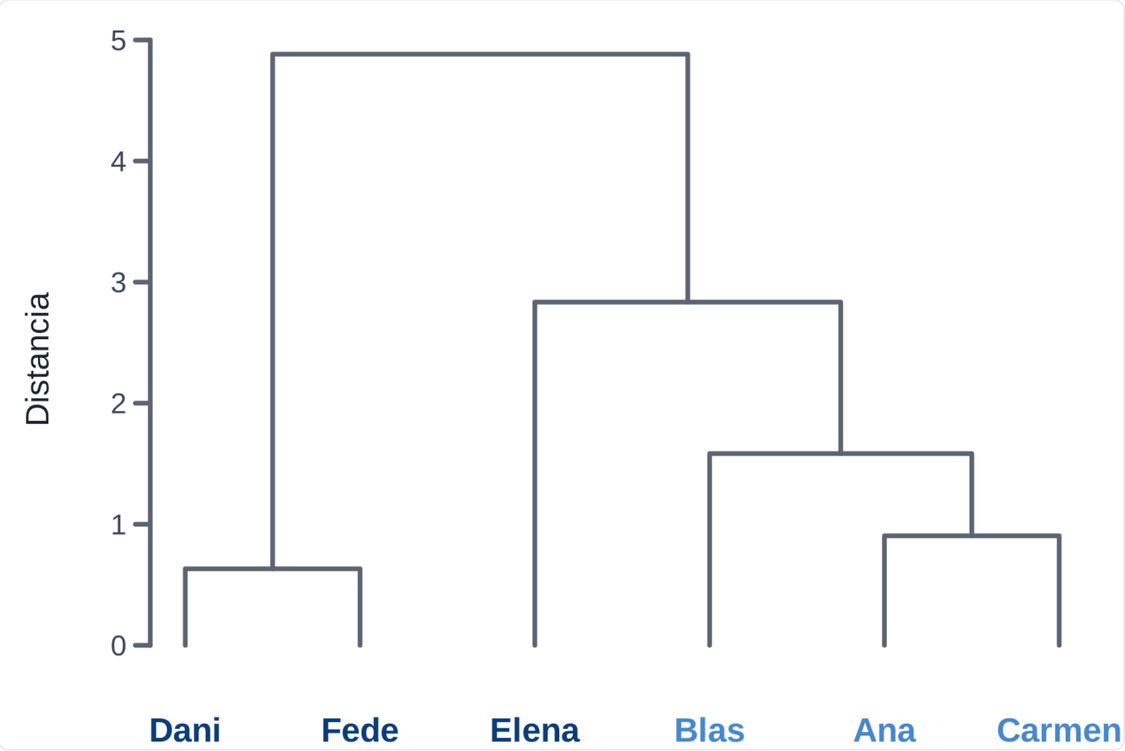
1. Todas las inyecciones

2. Sin blancos

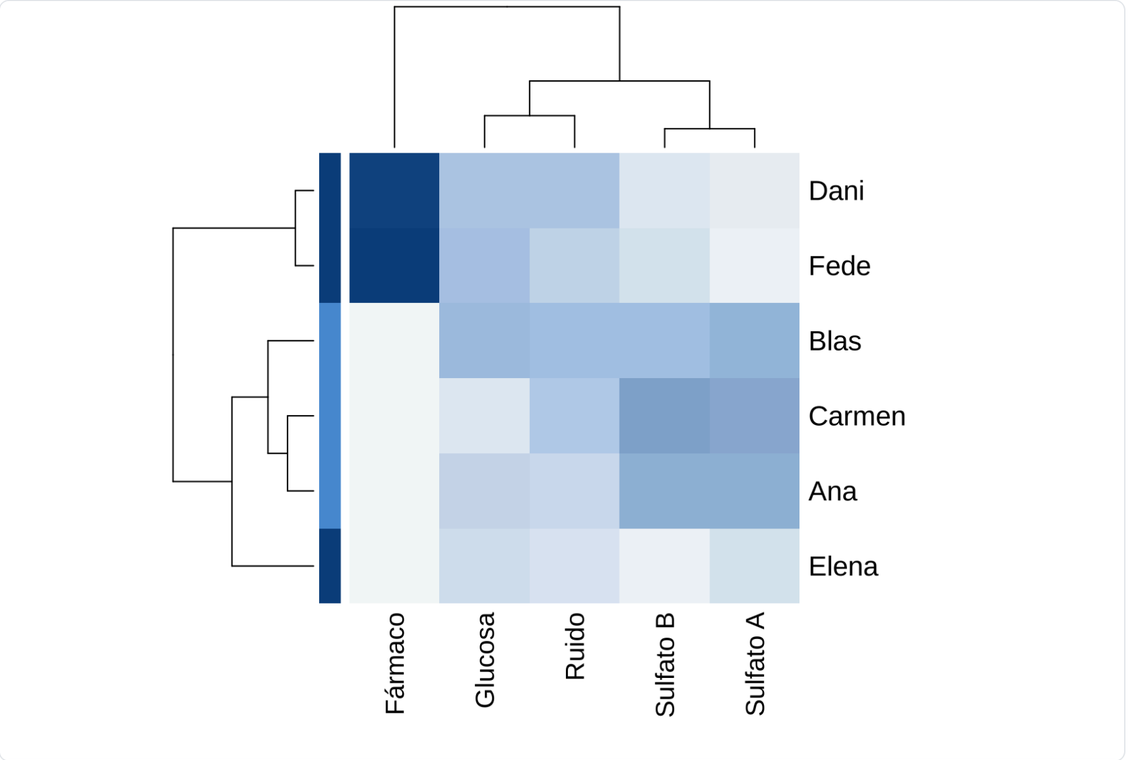
3. Solo muestras

Un PCA nuevo en cada paso

Clustering jerárquico



Dendrograma de las muestras



Heatmap

Dani y Fede aparte, **Elena** con los sanos y los **dos sulfatos** juntos

2. Supervisado

Con información de los grupos

PLS-DA



una puntuación de 0 a 1

Random Forest



muchos árboles que votan

Ambos requieren validación

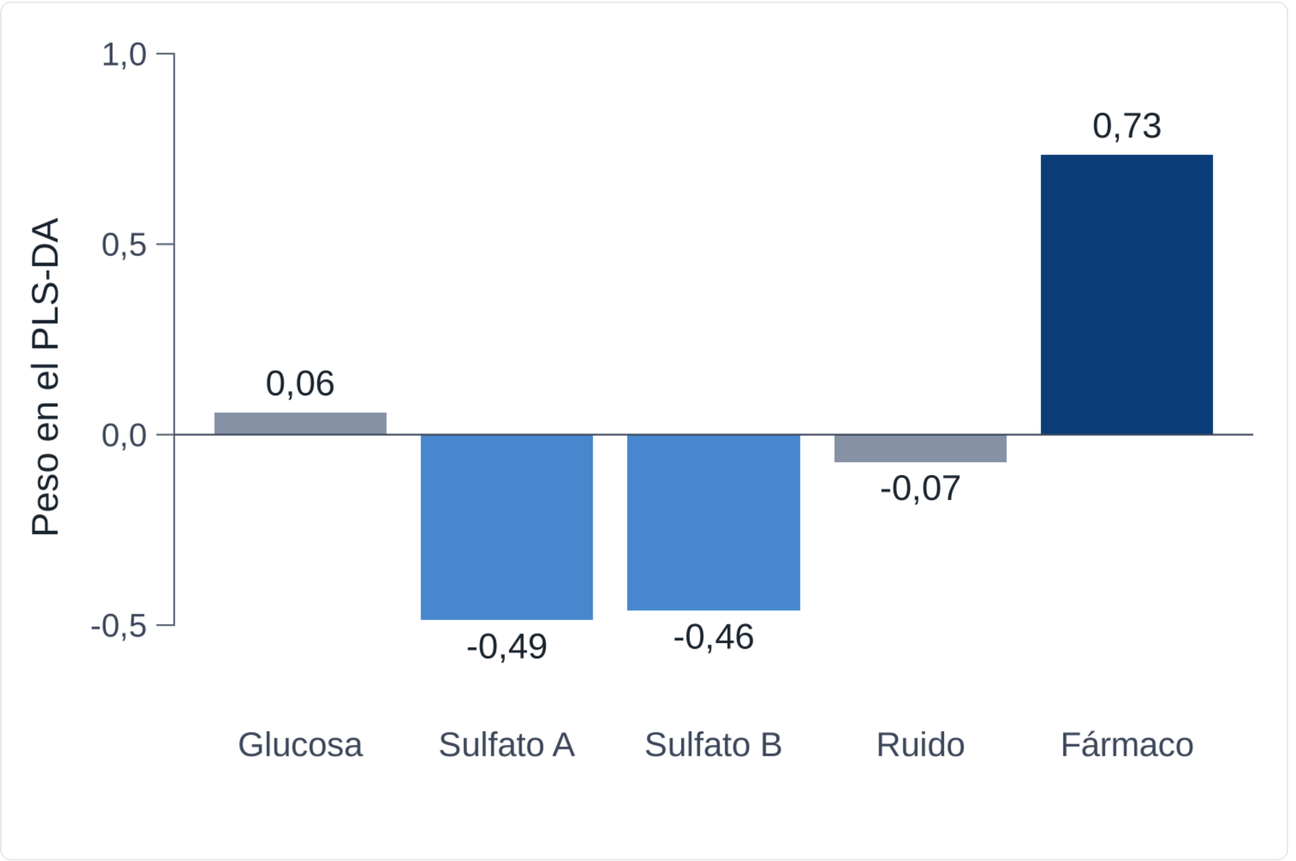
PLS-DA

Ana 0 Blas 0 Carmen 0

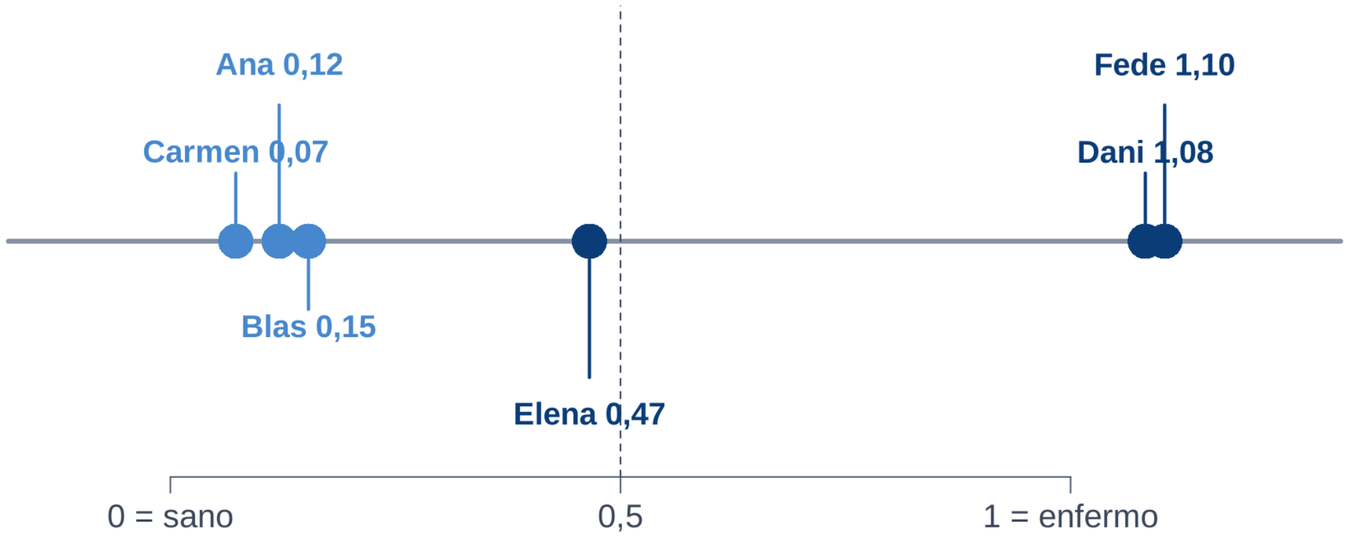
Dani 1 Elena 1 Fede 1

Busca la combinación de compuestos que **mejor predice** ese 0 o 1

Da un **peso** a cada compuesto



PLS-DA, predicciones y R²Y



	Ana	Blas	Carmen	Dani	Elena	Fede	Suma
Real	0	0	0	1	1	1	
Predicho	0,12	0,15	0,07	1,08	0,47	1,10	
Fallo²	0,014	0,023	0,005	0,006	**0,281**	0,010	**0,34**
Sin modelo²	0,25	0,25	0,25	0,25	0,25	0,25	**1,50**

Coeficiente de determinación

$R^2Y = 1 - 0{,}34 / 1{,}50$

= 0,77

Calculado con las mismas personas del modelo

Validación cruzada dejando uno fuera

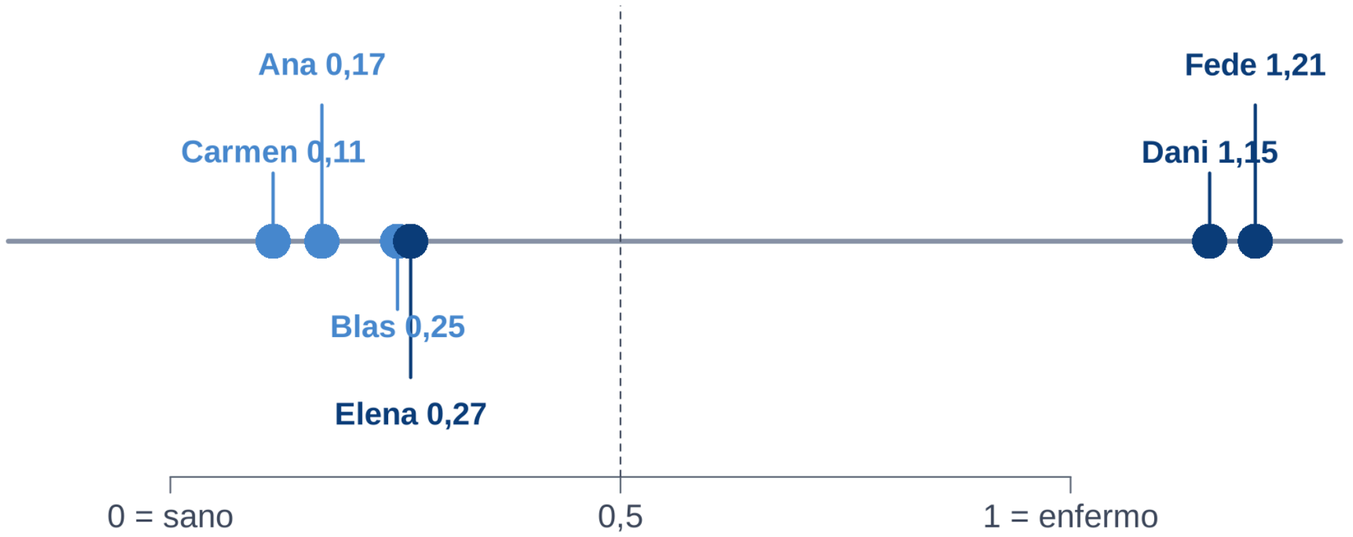
Vuelta 1	**Ana**	Blas	Carmen	Dani	Elena	Fede
Vuelta 2	Ana	**Blas**	Carmen	Dani	Elena	Fede
Vuelta 3	Ana	Blas	**Carmen**	Dani	Elena	Fede
Vuelta 4	Ana	Blas	Carmen	**Dani**	Elena	Fede
Vuelta 5	Ana	Blas	Carmen	Dani	**Elena**	Fede
Vuelta 6	Ana	Blas	Carmen	Dani	Elena	**Fede**

construyen el modelo

se predice sin haberla visto

En cada vuelta se rehace **todo**: medias, escalado y pesos

Predicciones en validación cruzada y Q²



	Ana	Blas	Carmen	Dani	Elena	Fede	Suma
Real	0	0	0	1	1	1	
Sin verla	0,17	0,25	0,11	1,15	0,27	1,21	
Fallo²	0,029	0,063	0,012	0,023	**0,533**	0,044	**0,70**
Sin modelo²	0,25	0,25	0,25	0,25	0,25	0,25	**1,50**

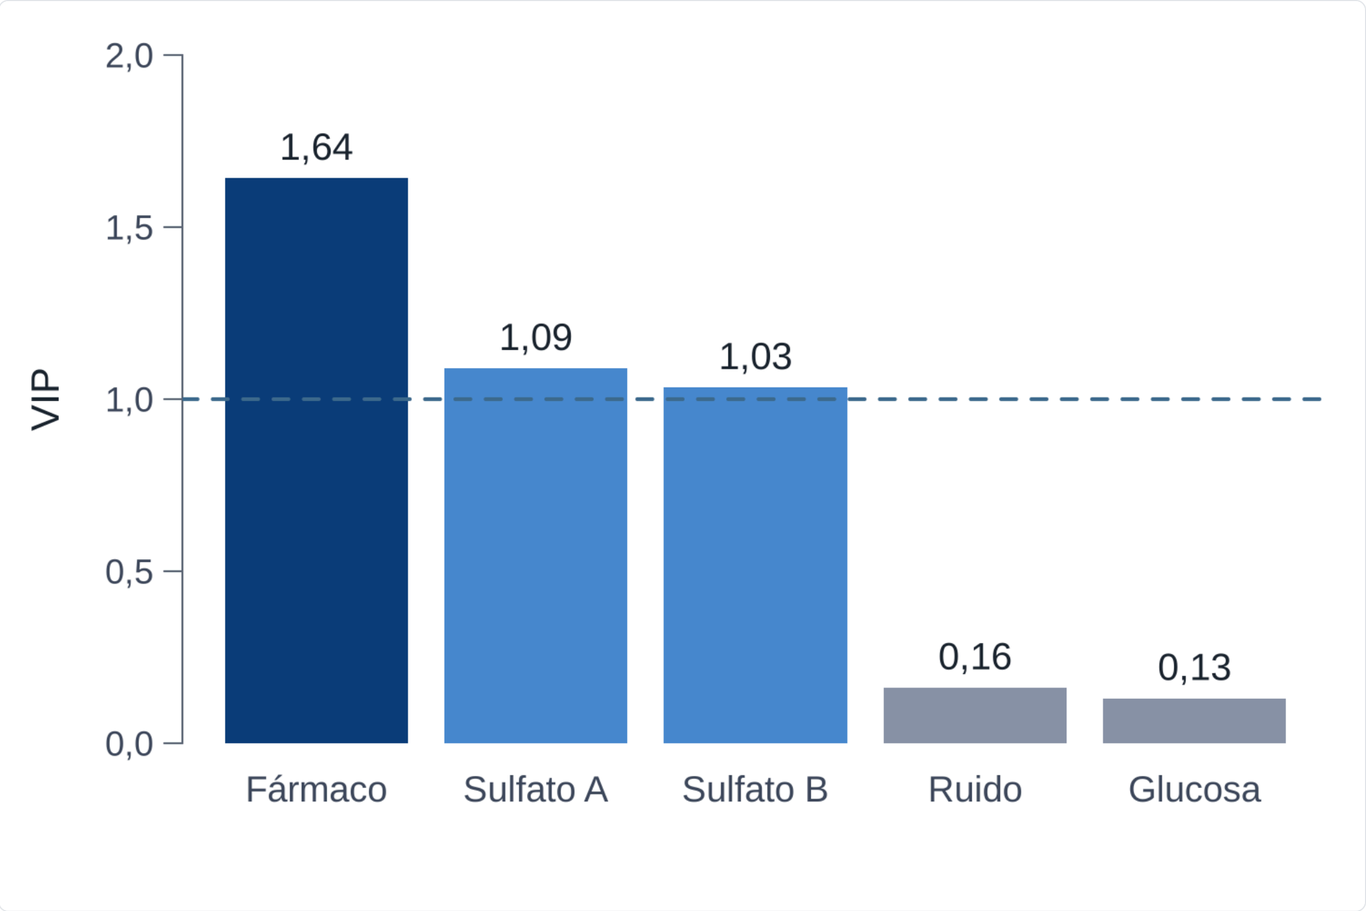
R² predictivo

$Q^2 = 1 - 0{,}70 / 1{,}50$

= 0,53

Elena (enferma): 0,27

Importancia de las variables (VIP)



Criterio habitual: **VIP > 1**

Sulfatos por encima de 1, pero **el fármaco en primer lugar**

No es una prueba de significación

Random Forest

Un árbol

¿Sulfato A por debajo de 11?

Sí → Dani, Elena, Fede

No → Ana, Blas, Carmen

6 de 6 bien

Otro árbol

¿Fármaco alto?

Sí → Dani, Fede

No → Ana, Blas, Carmen, Elena

5 de 6: falla Elena

Una persona nueva: enfermo | enfermo | sano | enfermo | enfermo → **Enfermo, 4 votos de 5**

Construcción de los árboles

Árbol 1

Muestra

Blas | Carmen ×2 | Elena ×3

Fuera de la bolsa

Ana | Dani | Fede

¿Sulfato B bajo?

Separa a los seis

Árbol 2

Muestra

Blas ×2 | Dani | Elena ×2 | Fede

Fuera de la bolsa

Ana | Carmen

¿Glucosa baja?

Por azar

Árbol 3

Muestra

Blas ×2 | Carmen | Dani | Fede ×2

Fuera de la bolsa

Ana | Elena

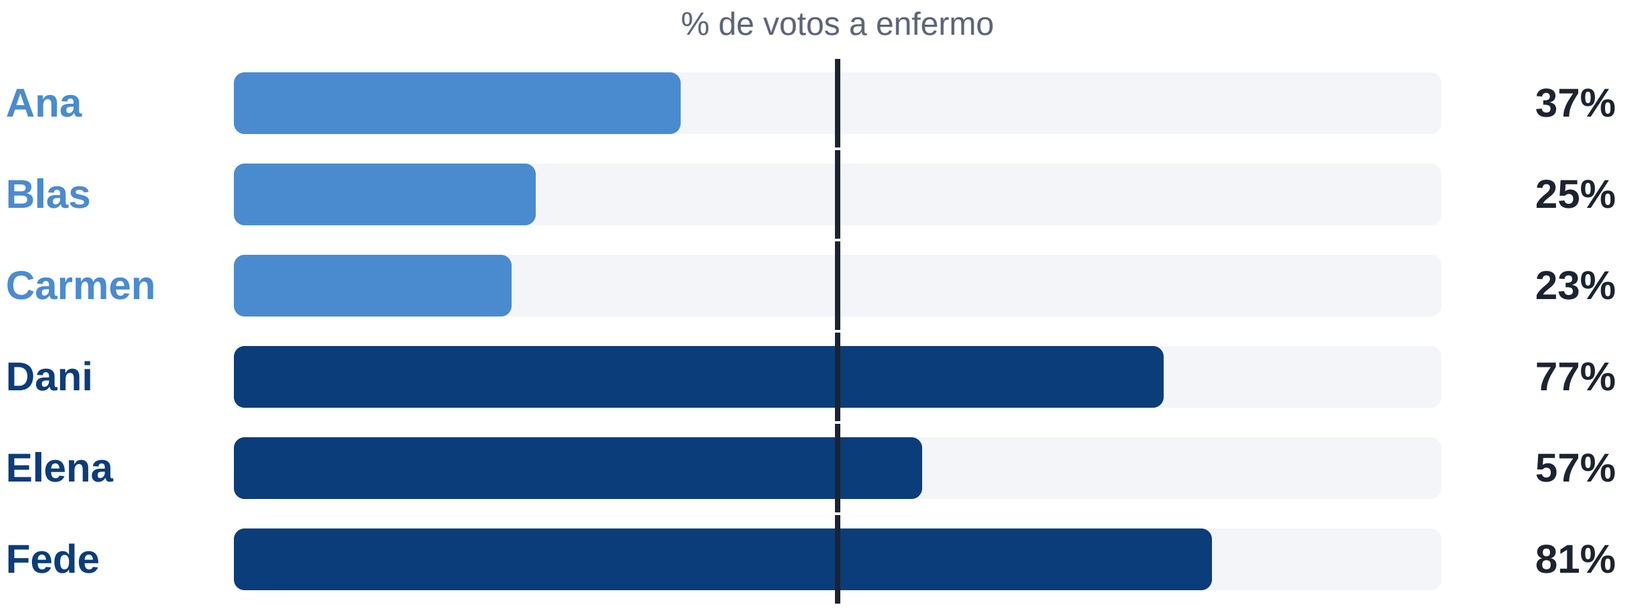
¿Fármaco alto?

Confusor

Personas sorteadas **con repetición**: unas salen dos o tres veces, otras se quedan fuera

En cada pregunta, solo puede elegir entre **2 compuestos al azar**

Error fuera de la bolsa (OOB)



Cada persona, juzgada por unos **150 a 180 árboles** de 500

Elena: 57%, enferma

El PLS-DA la daba casi por sana: 0,27